

DOCUMENTO TÉCNICO

Cientista do beOn Labs

Visão técnica do Método Experimento (METAEXP):
arquitetura multiagente, dados, modelos e o plano da Fase 1

FASE 1

**Cientista inteligente com
o histórico do Lab**

FASE 2

**Pipeline multiagente de
execução**

CONTEÚDO

Sumário

•	Resumo executivo		
1	O Método Experimento		
	1.1 Objetivo	1.3 O ciclo e os gates	1.5 Papéis e jornadas
	1.2 Princípios	1.4 Regras da ficha	1.6 O metaexperimento
2	Arquitetura-alvo multiagente		
	2.1 Visão em camadas	2.3 Agentes e skills	2.5 O que já existe e o que falta
	2.2 Princípios de arquitetura	2.4 Contratos entre agentes	
3	Dados		
	3.1 Mapa de dados	3.3 O registro Experimento	3.5 LGPD e segurança
	3.2 Pipeline do histórico	3.4 Armazenamento e versionamento	3.6 Dados sintéticos
4	Fase 1: um Cientista muito inteligente		
	4.1 Definição de pronto	4.4 Busca no histórico	4.7 E ajuste fino de modelo?
	4.2 As seis alavancas de inteligência	4.5 Datasets da Fase 1	4.8 Plano da Fase 1
	4.3 Arquitetura do Cientista	4.6 Avaliação do Cientista	4.9 Quem faz o quê
5	Fase 2: pipeline multiagente		
	5.1 Fluxo	5.3 Golden paths como código	
	5.2 Execução isolada	5.4 Entrada da Fase 2	
6	Modelos e onde rodá-los		
	6.1 Estratégia	6.2 Famílias open source para considerar	6.3 Protocolo de benchmark interno
			6.4 Onde rodar GPUs
7	Plataforma e engenharia		
	7.1 Stack de referência	7.2 Observabilidade e custo	7.3 Segurança
8	Riscos, decisões e próximos passos		
	8.1 Riscos	8.2 Perguntas em aberto	8.3 Próximas duas semanas
A	Apêndices		
	A.1 Glossário	A.3 Rubrica do juiz (resumo)	
	A.2 Campos da ficha	A.4 Referências	



Resumo executivo

O beOn Labs recebe desafios tecnológicos de várias áreas e os transforma em experimentos. Hoje, boa parte do esforço está antes do experimento começar: entender o problema, chegar a uma hipótese mensurável, definir métricas com critério numérico, confirmar que os dados existem e montar a ficha no padrão oficial. Esse trabalho é repetitivo, depende de poucas pessoas experientes e o conhecimento acumulado em fichas e relatórios antigos quase não é reaproveitado.

O **METAEXP** é a plataforma interna de experimentação do Lab, conduzida por agentes de IA que seguem o Método Experimento. Ela é, ao mesmo tempo, um produto e um experimento: o **metaexperimento** mede se a plataforma reduz o lead time, mantém o rigor do método e evita interrupções tardias.

5

agentes no ciclo completo

4

gates com decisão humana

Fase 1

Cientista inteligente com o histórico do Lab

Fase 2

pipeline multiagente de execução

A tese em uma frase

Um Cientista que conhece o método de cor e lembra de tudo o que o Lab já fez conduz o solicitante até uma ficha aprovável em uma conversa, e não em semanas.

O que este documento define

- **O método** (capítulo 1): objetivo, princípios, ciclo de cinco agentes, gates G0 a G3 e as hipóteses do metaexperimento.
- **A arquitetura-alvo multiagente** (capítulo 2): camadas, agentes, skills de cada agente, orquestração e contratos de dados. A arquitetura é desenhada completa desde o início, mesmo que a construção seja em fases.
- **Os dados** (capítulo 3): todos os tipos de dados que o ciclo produz e consome, o pipeline do histórico de fichas e relatórios, armazenamento e LGPD.
- **A Fase 1** (capítulo 4): como deixar o Cientista muito mais inteligente com o histórico do Lab, com datasets, arquitetura de contexto, avaliação e plano em sprints.
- **A Fase 2** (capítulo 5): o pipeline de execução com Analista de Dados, Desenvolvedor, QA e Analista.
- **Modelos e GPU** (capítulo 6): onde usar Claude, onde usar modelos open source, um protocolo de benchmark interno e as opções de onde hospedar GPUs.
- **Plataforma, riscos e decisões** (capítulos 7 e 8).

Decisões que precisamos tomar agora

#	Decisão	Por que importa	Prazo
1	Quem libera o acesso ao histórico de fichas, relatórios e pareceres	Sem histórico não existe Fase 1: é a matéria-prima da memória do Cientista	Semana 1
2	Acesso corporativo ao Claude e orçamento mensal	O Cientista roda em Claude desde o primeiro dia	Semana 1
3	Regras de uso dos dados (LGPD) para o corpus	Define o que pode ser indexado e onde fica guardado	Semana 2
4	Sponsor do METAEXP como produto	Decide prioridade e aprova o veredito do metaexperimento	Semana 2
5	Onde hospedar modelos open source (nuvem ou on-premises)	Necessário a partir da Fase 2 e para dados sensíveis	Semana 8

01

O Método Experimento

1.1 Objetivo

O Método Experimento é o padrão do beOn Labs para transformar uma ideia em um teste controlado, com hipótese mensurável, critérios de aceite numéricos e uma decisão clara no final. O METAEXP automatiza esse método com agentes de IA, mantendo as pessoas nas decisões que importam.


Os objetivos da plataforma são:

- **Reduzir o lead time** entre a chegada de um desafio e a ficha aprovada.
- **Garantir rigor:** toda ficha passa pelo checklist do método, sem exceção.
- **Falhar cedo:** descobrir na ficha ou na amostra, e não na análise, que um experimento não vai se sustentar.
- **Reaproveitar o conhecimento do Lab:** cada experimento novo parte do que já foi feito em casos parecidos.
- **Dar visibilidade:** lead time por gate, taxa de aprovação e vereditos medidos pela própria plataforma.

1.2 Princípios

Princípio	O que significa na prática
Hipótese antes de tecnologia	“Quero usar IA” não é um problema. O problema é descrito pelo impacto na operação.
Tudo é mensurável	Toda métrica tem critério de aceite com número e condição: “Acurácia ≥ 85%”, nunca “alta acurácia”.
Fail-fast	Gates G0 e G1 existem para interromper cedo: sem dados suficientes, o experimento para na amostra.
Humano decide	Agentes propõem; pessoas aprovam a ficha, confirmam os dados e aceitam o parecer.
Regras no código, não só no prompt	As regras do método são validadas por funções determinísticas, e não apenas pedidas ao modelo.
Tudo vira dado	Conversas, fichas, decisões e resultados são registrados e alimentam a próxima versão do Cientista.
Modelo plugável	Nenhum agente depende de um modelo específico: o gateway permite trocar ou combinar modelos.

1.3 O ciclo e os gates



Etapa	Agente	Entrada	Saída	Gate e critério
Ficha	Cientista	Ideia ou documento do solicitante	Ficha completa no padrão oficial	G0: checklist do método completo e ficha aprovada pelo solicitante
Amostra	Analista de Dados	Ficha + dados enviados	Análise de amostra e data card	G1: volume ≥ mínimo calculado e qualidade aceitável
Construção	Desenvolvedor	Ficha + amostra + golden path	Código, execução e resultados	Sem gate próprio: alimenta o QA
Qualidade	QA	Solução + critérios da ficha	Avaliação Qk e feedback	G2: Qk ≥ 0,85 em até 5 iterações; senão, especialista humano
Resultado	Analista	Resultados + hipótese + métricas	Parecer com veredito	G3: solicitante aceita o parecer; sponsor decide piloto ou escala

1.4 Regras da ficha

Estas regras vêm do prompt oficial do Cientista e já estão implementadas como validações em `metaexp/metodo.py`:

- **Hipótese:** começa com “Acreditamos que”, tem no máximo 2 linhas e é mensurável. Formato: “Acreditamos que [ação] irá gerar [resultado mensurável] para [contexto].”
- **Objetivo ≠ hipótese:** o objetivo descreve o que será realizado; a hipótese, o que se espera comprovar.
- **Métricas:** toda métrica tem critério de aceite com valor numérico e condição clara de sucesso.
- **Nome do experimento:** no máximo 3 palavras, objetivo e executivo.
- **Responsáveis:** todo experimento tem BO (responsável) e SPONSOR (patrocinador).
- **Fluxo da conversa:** Problema → Impacto → Objetivo → Hipótese → Metodologia → Amostra → Métricas → Critérios, uma pergunta por vez, no máximo 5 linhas por mensagem.

- **Auto-ingestão:** se a pessoa envia um texto com mais de 400 caracteres ou 3 ou mais seções, o Cientista extrai tudo de uma vez e pergunta só o que falta.
- **Amostra:** para estimar uma proporção com 95% de confiança e margem de 5 p.p., $n \approx 385$. Em busca e resposta (RAG), a referência é 400 pares pergunta-resposta; abaixo de 250, o resultado é indicativo.

1.5 Papéis e jornadas

Papel	Quem é	Como o METAEXP trata
Solicitante	Área de negócio que procurou o Lab com um desafio	Conversa fluida, sem jargão técnico, profundidade de negócio. Sempre segue para a bancada do Lab.
Desenvolvedor	Dev de qualquer área que quer construir algo	Técnico desde o início: baseline, abordagens com trade-offs, protocolo de avaliação e kit por stack.
Lab (pesquisa)	Pesquisadores do beOn Labs	Revisam fichas, confirmam amostra (G1), mantêm o método e os golden paths.
BO	Responsável pelo experimento na área	Obrigatório na ficha; acompanha a execução.
Sponsor	Patrocinador com poder de decisão	Obrigatório na ficha; decide piloto ou escala a partir do veredito.
Especialista revisor	Pessoa sênior do Lab	Assume quando o Ralph Loop atinge 5 iterações sem qualidade.

1.6 O metaexperimento

O próprio METAEXP é avaliado com o método. As hipóteses e critérios abaixo definem o veredito ao final da Onda 4:

Hipótese	Critério de aceite	Como medir
H1. Acreditamos que o Cientista reduzirá o lead time da ficha	Redução entre 50% e 70% vs. histórico	Data de entrada do desafio até a ficha aprovada, comparada às fichas manuais
H2. Acreditamos que as fichas do Cientista convergirão para o padrão do Lab	Convergência > 80%	Revisão cega: fichas do Cientista e manuais avaliadas pelo Lab sem saber a origem
H3. Acreditamos que o Ralph Loop eliminará entregas vazias ou quebradas	0 outputs vazios em 50 execuções	Registro de cada iteração do QA
H4. Acreditamos que o gate G0 reduzirá interrupções tardias	Redução $\geq$ 40% vs. histórico	Experimentos interrompidos depois do início da execução

Regra do veredito

GO se H1 a H3 forem confirmadas e a revisão cega der nota igual ou superior às fichas manuais. GO condicional se faltar uma delas com plano de correção. NO-GO nos demais casos.

02

Arquitetura-alvo multiagente

Mesmo construindo em fases, a arquitetura é desenhada completa desde o início. Assim, o Cientista da Fase 1 já nasce com os contratos, o armazenamento e a observabilidade que os outros agentes vão usar, e nada precisa ser refeito na Fase 2.

2.1 Visão em camadas



Camada	Responsabilidade	Tecnologia de referência
Canais	Onde as pessoas interagem: chat por papel, painel do Lab, integrações	Front web atual (protótipo), API REST + SSE
Orquestração	Estado do experimento, transições entre gates, aprovações, filas	Máquina de estados em Python; Temporal ou fila (Redis) na Fase 2
Agentes	Raciocínio e decisão de cada etapa do método	Claude via SDK, com ferramentas estritas e saídas estruturadas
Skills	Capacidades reutilizáveis de cada agente (instruções + ferramentas + referências)	Pacotes no formato Agent Skills (SKILL.md, scripts, referências)

Camada	Responsabilidade	Tecnologia de referência
Conhecimento	Método, golden paths, corpus de experimentos e playbooks	Markdown versionado + Postgres/pgvector
Dados	Persistência de documentos, registros, artefatos e telemetria	Postgres, object storage (S3 ou MinIO)
Plataforma	Modelos, execução isolada, observabilidade, segurança	Gateway de modelos, vLLM, containers, OpenTelemetry, SSO

2.2 Princípios de arquitetura

- **Orquestração determinística, raciocínio nos agentes.** Quem decide a próxima etapa é a máquina de estados; o agente decide o conteúdo da etapa. Isso deixa o fluxo auditável e previsível.
- **Contratos tipados entre agentes.** Cada agente entrega um objeto validado (Pydantic): Ficha, AnaliseAmostra, PlanoTecnico, AvaliacaoQA, Resultados e Parecer. Um agente nunca lê a conversa de outro: lê o contrato.
- **Humano no gate.** Toda transição de gate grava quem aprovou, quando e com qual versão do artefato.
- **Modelo plugável.** Todo acesso a modelo passa por um gateway que registra custo, aplica cota e permite trocar Claude por um modelo open source, ou combiná-los, sem mudar o agente.
- **Skills como unidade de reuso.** Uma skill é uma pasta com instruções, scripts e referências. A mesma skill (por exemplo, cálculo amostral) serve ao Cientista e ao Analista de Dados.
- **Tudo observável.** Cada turno gera um trace com contexto, ferramentas chamadas, tokens, cache, latência e custo.

2.3 Agentes e skills

Cada agente tem uma missão, um contrato de saída, um conjunto de skills e um gate. A tabela resume; as fichas de cada agente detalham.

Agente	Missão	Contrato de saída	Gate	Fase
Cientista	Transformar a ideia em ficha aprovável seguindo o método	Ficha	G0	1
Analista de Dados	Provar que os dados sustentam o teste da hipótese	AnaliseAmostra	G1	1 (parcial) e 2
Desenvolvedor	Construir e executar a solução a partir do golden path	PlanoTecnico + Resultados	—	2
QA	Verificar a solução contra os critérios da ficha	AvaliacaoQA (Qk)	G2	2
Analista	Comparar resultados com a hipótese e dar o veredito	Parecer	G3	2

Cientista

Skill	O que faz	Ferramentas
Entrevista do método	Conduz o fluxo Problema → Critérios, uma pergunta por vez, no tom do papel	atualizar_ficha, sugerir_respostas
Auto-ingestão	Extrai de um documento longo tudo o que cabe na ficha e pergunta só o que falta	atualizar_ficha
Memória do Lab	Busca experimentos semelhantes e usa critérios, amostras e lições como âncora	buscar_experimentos_similares
Classificação técnica	Identifica tecnologia, técnica e golden path	classificar_experimento
Cálculo amostral	Calcula o tamanho mínimo e explica na linguagem do papel	calcular_tamanho_amostra, solicitar_dados
Desenho técnico (dev)	Abordagens com trade-offs, baseline e protocolo de avaliação	propor_abordagens, registrar_desenho_tecnico
Gerador de Ficha	Valida o checklist e gera a ficha no template oficial	gerar_ficha
Encaminhamento	Envia a ficha à bancada ou entrega o kit ao desenvolvedor	encaminhar

Analista de Dados (Agente de Amostra e Dados)

Skill	O que faz	Ferramentas
Perfil do dataset	Esquema, tipos, nulos, duplicados, distribuição e balanceamento de classes	profiling (pandas)
Suficiência amostral	Compara o volume válido com o mínimo calculado para a margem desejada	stats
Detecção de PII	Encontra e mascara dados pessoais antes de qualquer uso	Presidio + spaCy pt
Divisão de dados	Separa treino, validação e teste sem vazamento	scikit-learn
Data card	Documenta origem, cobertura, limitações e versão do dataset	template

Desenvolvedor

Skill	O que faz	Ferramentas
Plano técnico	Etapas, componentes e qual critério da ficha cada parte cobre	saída estruturada
Scaffolding por golden path	Parte do padrão do Lab para a técnica (RAG, classificação, previsão...)	templates de código
Geração e execução de código	Escreve código modular e executa no sandbox	sandbox, sistema de arquivos
Instrumentação	Garante que cada métrica da ficha é calculada e registrada	biblioteca de métricas

QA

Skill	O que faz	Ferramentas
Testes a partir da ficha	Deriva um teste verificável para cada critério de aceite	saída estruturada
Índice de qualidade	Calcula $Q_k = e \cdot o \cdot d \cdot S$ (executa, outputs existem, dados válidos, aderência)	sandbox
Feedback acionável	Devolve correções concretas para a próxima iteração	—
Escalonamento	Encaminha ao especialista quando $K_{max} = 5$ sem atingir $Q_{min} = 0,85$	fila de revisão

Analista

Skill	O que faz	Ferramentas
Comparação com critérios	Métrica a métrica: meta, resultado, atendida ou não	saída estruturada
Inferência estatística	Intervalos de confiança e significância quando aplicável	stats (scipy)
Veredito	Validada, parcialmente comprovada, invalidada ou inconclusiva	—
Relatório executivo	Manchete, evidências, riscos, próximos passos e oportunidades	template do relatório

2.4 Contratos entre agentes

Os contratos já existem em `metaexp/schemas.py` e são a espinha dorsal da arquitetura:

Contrato	Produzido por	Consumido por	Campos principais
Ficha	Cientista	Todos	título, problema, impacto, objetivo, hipótese, metodologia, métricas com critério, dados, amostra, BO, sponsor, skills, detalhes técnicos
AnaliseAmostra	Analista de Dados	Desenvolvedor, QA	registros válidos, tamanho mínimo, suficiente, qualidade, achados, alertas, decisão G1
PlanoTecnico	Desenvolvedor	QA	abordagem, etapas, componentes, critérios atendidos, riscos técnicos
AvaliacaoQA	QA	Desenvolvedor, orquestrador	e, o, d, critérios avaliados com evidência, feedback; Q_k calculado
Resultados	Desenvolvedor	Analista	métricas (meta, resultado, atendida), observações, simulado ou real
Parecer	Analista	Solicitante, sponsor	veredito, manchete, resumo, evidências, riscos, próximos passos, oportunidades
Experimento	Ingestão / plataforma	Cientista (memória), avaliação	todos os anteriores + origem real/sintético, conversa, lead time, tags

2.5 O que já existe e o que falta

Componente	Hoje no repositório	Para o alvo
Cientista	Agente com prompt oficial, jornadas por papel, 11 ferramentas, auto-ingestão	Memória do Lab real (corpus do histórico), playbooks, avaliação contínua
Regras do método	Validações determinísticas e checklist em metodo.py	Congelar v1 com o Lab e versionar mudanças
Bancada (Fase 2)	Agentes de Dados, Desenvolvedor, QA e Analista com executor simulado	Execução real em sandbox, golden paths como código
Corpus	Formato Experimento, busca BM25, 7 sementes sintéticas	Histórico real ingerido, busca híbrida com embeddings
Sintético	Gerador com taxonomia, lote e controle de qualidade	Taxonomia calibrada pela distribuição real
Avaliação	Runner com casos e checagem de jornada	Solicitante simulado, juiz, revisão cega, gate em CI
Plataforma	FastAPI + SSE, sessões em JSON, front protótipo	Postgres, SSO, gateway de modelos, observabilidade

03

Dados

Dados são o que diferencia um Cientista genérico de um Cientista do beOn Labs. Este capítulo lista todos os tipos de dados que o ciclo precisa, de onde vêm, quem produz e quem usa.


3.1 Mapa de dados

Tipo	Exemplos	Origem	Sensibilidade	Quem usa	Fase
Conhecimento do método	Método oficial, template da ficha, golden paths, glossário	Lab	Interna	Todos os agentes	1
Histórico bruto	Fichas, relatórios, pareceres, apresentações, atas	Drive, SharePoint, e-mail	Pode ter PII	Ingestão	1
Corpus estruturado real	Registros Experimento extraídos do histórico	Ingestão + revisão	Anonimizada	Cientista, avaliação, sintético	1
Registros ouro	20 a 50 experimentos curados campo a campo	Lab	Anonimizada	Avaliação (gabarito)	1
Playbooks	Lições por domínio e técnica, critérios típicos, armadilhas	Destilados do corpus + Lab	Interna	Cientista	1
Sintético	Experimentos e conversas sintéticas	Gerador (Claude)	Sem PII	Cobertura, avaliação, few-shot	1
Conversas e sessões	Turnos, versões da ficha, eventos de jornada	Plataforma	Pode ter PII	Avaliação, melhoria	1
Avaliação	Casos de teste, personas, notas do juiz, revisão cega	Time + plataforma	Interna	CI, veredito	1
Feedback humano	Correções do Lab nas fichas, aprovações e recusas	Lab, solicitantes	Interna	Melhoria, ajuste fino	1
Telemetria e custo	Tokens, cache, latência, custo por ficha, lead time por gate	Plataforma	Interna	Painel, H1 e H4	1
Dados do experimento	Datasets enviados pelo solicitante (planilhas, logs, textos)	Áreas	Alta	Analista de Dados, Dev	2
Artefatos de execução	Código, logs, outputs, métricas, rodadas do Ralph Loop	Sandbox	Herda dos dados	QA, Analista	2

Tipo	Exemplos	Origem	Sensibilidade	Quem usa	Fase
Governança	Decisões de gate, auditoria, versões aprovadas	Plataforma	Interna	Lab, sponsor	1 e 2

3.2 Pipeline do histórico

O histórico de fichas e relatórios é o insumo mais valioso da Fase 1. O pipeline abaixo o transforma em um corpus consultável, auditável e seguro.



Etapa	Como	Ferramentas	Controle de qualidade
Coleta	Uma pasta por experimento: ficha, relatório, parecer e anexos, com nomes padronizados	Script + planilha de inventário	Inventário fecha com a contagem por ano e área
Anonimização	Mascara nomes, CPFs, telefones, e-mails e dados de clientes antes de extrair	Presidio + spaCy pt, regras próprias	Amostra revisada; zero PII nos registros
Extração	Converte PDF/DOCX/PPTX em texto e o modelo preenche o registro Experimento com saída estruturada	Docling ou pdfplumber; Claude com schema	Campos com evidência (trecho de origem)
Validação	Esquema Pydantic + regras do método; registros com falha vão para revisão	metaexp ingerir	% de registros válidos na primeira passada
Revisão ouro	Lab revisa 20 registros campo a campo (depois 50)	Planilha ou tela de revisão	Concordância entre revisores
Indexação	Busca híbrida: BM25 + embeddings + reranker, com filtros por domínio, técnica e veredito	Postgres + pgvector	Recall@5 nas consultas de avaliação

O histórico é imperfeito, e tudo bem

Fichas antigas não seguem o método atual (hipótese sem “Acreditamos que”, critérios sem número). A ingestão registra o que existe, marca o que está fora do padrão e o Cientista aprende com os dois: o que funcionou e o que gerou retrabalho.

3.3 O registro Experimento

Cada experimento do histórico vira um registro com: a ficha (no formato atual, normalizada), a descrição da amostra, o plano técnico, os resultados, o parecer, a conversa de elaboração quando existir, o lead time, tags e a **origem** (real ou sintético). Os campos de texto guardam o trecho do documento de onde vieram, para auditoria.

Unidades de indexação para a busca:

- **Resumo do experimento** (problema, hipótese, técnica, veredito): para achar casos parecidos.
- **Métricas e critérios**: para sugerir critérios realistas por técnica e domínio.
- **Parecer e lições**: para alertar sobre riscos e falhas que já aconteceram.
- **Amostra**: para comparar volumes e qualidade de dados em casos semelhantes.

3.4 Armazenamento e versionamento

O quê	Onde	Por quê
Documentos brutos	Object storage com acesso restrito	Fonte de verdade; nunca saem do ambiente corporativo
Registros, sessões, gates	Postgres	Consultas, integridade e auditoria
Embeddings	pgvector no mesmo Postgres	Menos uma peça de infraestrutura; suficiente para dezenas de milhares de trechos
Versões do corpus	Snapshots versionados (tag por versão) + data card	Reprodutibilidade: toda avaliação cita a versão do corpus
Artefatos de execução (Fase 2)	Object storage por experimento	Rastreabilidade do que o QA e o Analista avaliaram

3.5 LGPD e segurança

- Classificar cada fonte antes da ingestão (pública interna, confidencial, dados pessoais).
- Anonimizar na ingestão, não na consulta: o corpus nunca contém PII.
- Documentos reais ficam fora do Git (já configurado: `data/real` e `data/corpus/real` no `.gitignore`).
- Acesso por papel (RBAC) e trilha de auditoria de quem consultou o quê.
- Dados de experimentos com informação sensível rodam em modelo hospedado no ambiente corporativo (capítulo 6).
- Validar as regras com Segurança da Informação e Jurídico antes da primeira ingestão (entregável D2).

3.6 Dados sintéticos

O sintético resolve três problemas: cobrir domínios e técnicas pouco presentes no histórico, criar conversas de treino e avaliação sem expor dados reais, e testar casos-limite (dados insuficientes, hipótese vaga, solicitante apressado).

- **Taxonomia calibrada:** domínio, técnica, situação dos dados e veredito com pesos tirados da distribuição real do histórico.
- **Ancorado no real:** cada sintético cita a semente real que o inspirou e respeita o método atual.
- **Filtro de qualidade automático** (regras do método + juiz) e revisão humana de 10% da amostra.
- **Sempre rotulado** como sintético, e nunca usado como gabarito de avaliação: o gabarito são os registros ouro.
- Meta da Fase 1: 200 experimentos sintéticos de boa qualidade.

04

Fase 1: um Cientista muito inteligente

A Fase 1 tem um único objetivo: deixar o Cientista do beOn Labs muito melhor do que um assistente genérico, usando o que o Lab já sabe. O resto da plataforma evolui o mínimo necessário para isso.

4.1 Definição de pronto

Metas propostas, a confirmar com o Lab na Onda 0:

Métrica	Meta	Como medir
Fichas completas e válidas no conjunto de avaliação	≥ 90%	Checklist determinístico ao final de cada conversa simulada
Conformidade com as regras do método	100%	Validações de metodo.py (hipótese, critérios, nome, BO e sponsor)
Turnos até a ficha (mediana)	≤ 14	Contagem por conversa simulada
Perguntas repetidas ou já respondidas	≤ 5% dos turnos	Juiz automático
Qualidade na revisão cega (1 a 5)	≥ 4,0 e ≥ fichas manuais	Lab avalia sem saber a origem
Casos semelhantes relevantes no top-3	≥ 80%	Consultas de avaliação com resposta esperada
Custo por ficha	Medido e dentro do orçamento	Telemetria do gateway

4.2 As seis alavancas de inteligência

Em ordem de retorno sobre esforço. As três primeiras dão a maior parte do ganho; ajuste fino de modelo só entra se a avaliação mostrar que as outras não bastam.

#	Alavanca	O que muda no Cientista	Esforço
1	Método codificado	Prompt oficial + validações determinísticas + checklist. Já existe; falta calibrar com conversas reais.	Baixo
2	Memória do Lab (RAG)	A cada problema, o Cientista vê os experimentos mais parecidos: critérios usados, amostras, vereditos e lições. Sugere com base no que o Lab já fez.	Médio
3	Playbooks destilados	Cartões curtos por domínio e técnica, gerados do corpus e revisados pelo Lab: métricas típicas, faixas de critério, tamanhos de amostra, armadilhas comuns.	Médio

#	Alavanca	O que muda no Cientista	Esforço
4	Ferramentas	Cálculo amostral, perfil de arquivos, classificação técnica e busca, sempre com resultado verificável.	Baixo
5	Avaliação contínua	Solicitante simulado, juiz e revisão cega. É o que permite melhorar sem regredir.	Médio
6	Ciclo de feedback	Cada correção do Lab vira um caso de avaliação e um exemplo. O Cientista melhora a cada ficha real.	Contínuo

Exemplo de playbook

Domínio atendimento · técnica RAG. Métricas que o Lab usa: Recall@5, taxa de resposta correta, tempo médio de atendimento. Faixas de critério aprovadas: Recall@5 ≥ 0,80; acerto ≥ 85%. Amostra típica: 400 pares pergunta-resposta. Armadilhas vistas: base de conhecimento desatualizada, perguntas reais diferentes do FAQ, ausência de baseline humano. 6 experimentos de referência.

4.3 Arquitetura do Cientista




Figura 4. Montagem do contexto do Cientista e seus serviços.

O contexto de cada turno é montado em seis camadas, da mais estável para a mais variável. As camadas estáveis ficam em cache de prompt, o que reduz custo e latência:

- 1. Método oficial e regras:** o prompt do Cientista. Muda só com nova versão do método.
- 2. Jornada do papel:** solicitante ou desenvolvedor, com as preferências escolhidas na entrada.
- 3. Playbook do domínio:** injetado quando o Cientista identifica domínio e técnica.
- 4. Casos semelhantes:** os 3 a 5 experimentos mais parecidos, resumidos, vindos da busca híbrida.
- 5. Estado da ficha:** campos preenchidos e pendências do checklist, para decidir a próxima pergunta.

6. Conversa: o histórico do chat, que só cresce (preserva o cache e o raciocínio).

4.4 Busca no histórico

- **Híbrida:** BM25 em português (já existe) + embeddings multilíngues + reranker. O BM25 acha termos exatos (sistemas, siglas); os vetores acham o significado.
- **Filtros:** domínio, técnica, situação dos dados e veredito. Casos invalidados também são úteis: mostram o que não funcionou.
- **Resumos, não documentos inteiros:** o Cientista recebe um resumo estruturado de cada caso, com link para o original.
- **Avaliada:** um conjunto de consultas com respostas esperadas mede Recall@5 e MRR. Se o BM25 sozinho bater a meta, os vetores ficam para depois (entregável C5).

4.5 Datasets da Fase 1

Dataset	Conteúdo	Volume-alvo	Responsável	Onda
Inventário do histórico	Lista de cada documento: local, formato, ano, área, dono	100%	LAB	0
Corpus real	Registros Experimento extraídos e validados	Todo o histórico disponível	IA + LAB	1
Registros ouro	Experimentos revisados campo a campo	20 → 50	LAB	1 e 2
Playbooks	Cartões por domínio e técnica	1 por combinação frequente	IA + LAB	2
Conjunto de avaliação	Conversas com solicitante simulado (personas) e gabaritos	15 → 60 casos	IA	1 e 2
Consultas de busca	Perguntas com experimentos esperados	50 consultas	IA + LAB	2
Sintético	Experimentos e conversas sintéticas calibradas	200	IA	2
Feedback do piloto	Correções do Lab e decisões de G0	Toda ficha real	PROD + LAB	3

4.6 Avaliação do Cientista

Sem avaliação, cada mudança no prompt é um palpite. O harness de avaliação roda conversas completas com um **solicitante simulado** (outro modelo, guiado por uma persona e por um caso ouro ou sintético) e mede o resultado.

Persona	O que testa
Negócio objetivo	Fluxo padrão; a ficha sai rápido e sem jargão
Negócio vago	O Cientista consegue chegar a uma hipótese mensurável sem impor a solução

Persona	O que testa
Desenvolvedor técnico	Profundidade: baseline, abordagens, protocolo de avaliação
Texto longo colado	Auto-ingestão: extrai tudo e pergunta só o que falta
Dados insuficientes	O Cientista calcula a amostra, pede mais e registra resultado indicativo
Pressa e respostas curtas	Mantém o rigor sem irritar; uma pergunta por vez

Três níveis de medida:

- **Determinístico:** ficha completa, regras do método, número de turnos, ferramentas chamadas corretamente.
- **Juiz automático:** rubrica de 1 a 5 para clareza, aderência à jornada, perguntas repetidas e qualidade da hipótese. O juiz é calibrado contra notas humanas (concordância medida).
- **Revisão cega humana:** o Lab avalia fichas do Cientista e manuais sem saber a origem. É a medida que decide H2.

Toda mudança de prompt, ferramenta ou modelo roda a avaliação no CI e mostra o placar antes e depois. Regressão bloqueia a mudança (entregável A3).

4.7 E ajuste fino de modelo?

Ajuste fino (SFT, DPO) de um modelo open source só faz sentido na Fase 1 se três condições forem verdadeiras:

1. Precisamos de um Cientista que rode totalmente dentro do ambiente corporativo.
2. Temos centenas de conversas e fichas de alta qualidade (reais revisadas + sintéticas filtradas).
3. A avaliação mostra lacunas que prompt, memória e playbooks não fecham.

Até lá, o mesmo dataset que serviria ao ajuste fino é usado para avaliação e exemplos dinâmicos. Se as condições forem atingidas, o caminho é LoRA/QLoRA sobre um modelo open source de porte médio, com as ferramentas do ecossistema Hugging Face (TRL) e avaliação idêntica à do Claude para comparar.

4.8 Plano da Fase 1

Alinhado ao mural do time (códigos entre parênteses). Ondas de duas a quatro semanas, com entregáveis pequenos e demonstráveis.

Onda	Semanas	Entregáveis	Marco
0 · Descoberta e base	1–2	Visão e métricas (P1), método v1 congelado (P2), template da ficha (P3), inventário do histórico (D1), regras LGPD (D2), acesso ao modelo (E1), primeiras conversas reais (C1)	Plano aprovado, histórico inventariado, acesso ao modelo
1 · Cientista v1	3–6	Coleta (D3), ingestão (D4), 20 registros ouro (D5), prompt v1 (C2), ferramentas estáveis (C3), auto-ingestão (C4), avaliação v0 (A1), baseline (A2), sessões em banco (E2), front no modelo real (E3), teste com usuários (P4)	Fichas válidas em 15 casos de teste

Onda	Semanas	Entregáveis	Marco
2 · Corpus e avaliação contínua	7–10	Taxonomia calibrada (D6), 200 sintéticos (D7), data card (D8), busca de semelhantes (C5), análise da amostra (C6), jornada do dev (C7), avaliação no CI (A3), revisão cega (A4), observabilidade e custo (E4), exportar ficha (E5)	Corpus versionado e avaliação a cada mudança
3 · Piloto	11–14	Áreas e sponsors (G1), SSO (E6), ambiente do piloto (E7), 10 fichas reais (G2), painel da esteira (G3), medir H1 e H4 (A5)	10 fichas reais de 2 áreas

4.9 Quem faz o quê

Perfil	Foco na Fase 1
Especialista de IA	Prompt e ferramentas do Cientista, ingestão com modelo, busca híbrida, playbooks, sintético, harness de avaliação e juiz
Engenharia de software	Banco e sessões, gateway de modelos, front ligado ao modelo real, observabilidade e custo, SSO, CI de avaliação, ambiente do piloto
Pesquisa do Lab	Dono do método, inventário e curadoria do histórico, registros ouro, revisão de playbooks, revisão cega
Produto	Visão e métricas, regras de dados com Jurídico, teste com usuários, áreas do piloto, acompanhamento de H1 e H4

05

Fase 2: pipeline multiagente

Com o Cientista entregando fichas aprovadas, a Fase 2 liga a bancada: a ficha aprovada no G0 vira automaticamente um experimento em execução, passando por dados, construção, qualidade e parecer.

5.1 Fluxo

- G0 aprovado** → o orquestrador cria o experimento e abre o espaço de trabalho (pasta de artefatos e sandbox).
- Analista de Dados** perfila o dataset, verifica PII e suficiência e gera o data card → **G1** com confirmação do Lab.
- Desenvolvedor** gera o plano técnico a partir do golden path, escreve o código e executa no sandbox.
- QA** deriva testes dos critérios, calcula Qk e devolve feedback; o Ralph Loop repete até $Qk \geq 0,85$ ou 5 iterações → **G2**.
- Analista** compara resultados com a hipótese, aplica a estatística e redige o parecer → **G3** com o solicitante.

5.2 Execução isolada

- Containers efêmeros por experimento, sem acesso à rede por padrão e com limites de CPU, memória, GPU e tempo.
- Imagens base por golden path (Python com bibliotecas de dados, de ML ou de RAG), mantidas pelo Lab.
- Dados montados só leitura; artefatos gravados no object storage do experimento.
- Isolamento reforçado (gVisor ou microVMs) para código gerado por modelo.

5.3 Golden paths como código

Hoje os golden paths são descrições. Na Fase 2 viram repositórios-modelo executáveis: estrutura de pastas, pipeline de avaliação, métricas já instrumentadas e um exemplo funcionando. O Desenvolvedor parte deles, e o QA sabe exatamente onde procurar os outputs.

5.4 Entrada da Fase 2

Onda	Semanas	Entregáveis	Marco
4 · Bancada e veredito	15–18	Execução em sandbox (B1), agentes da bancada com dados reais (B2), veredito do metaexperimento (G4)	Primeiro experimento ponta a ponta e veredito

06

Modelos e onde rodá-los

6.1 Estratégia

A plataforma usa dois tipos de modelo, cada um onde ele é melhor:

Uso	Modelo recomendado	Por quê
Cientista, Analista, juiz de avaliação	Claude (via gateway corporativo)	Melhor raciocínio, português corporativo e uso de ferramentas; menos esforço de engenharia; prompt caching reduz custo
Ingestão do histórico (extração estruturada)	Claude; open source como alternativa	Qualidade da extração é crítica para o corpus; volume baixo e pontual
Embeddings e reranker	Open source	Alto volume, custo marginal baixo, roda em uma GPU pequena ou até CPU
Detecção de PII	Open source (Presidio + spaCy)	Determinístico, auditável e local
Objeto do experimento (o que o solicitante quer testar)	Open source ou Claude, conforme a ficha	Dados sensíveis pedem modelo hospedado no ambiente corporativo
Contingência e soberania	Open source	Continuidade se a API externa ficar indisponível ou se a política exigir

6.2 Famílias open source para considerar

O cenário de modelos abertos muda a cada trimestre; a tabela é uma lista de partida qualitativa, não um ranking. Versões, licenças e números devem ser confirmados no benchmark interno (seção 6.3) antes de qualquer decisão.

Família	Formato	Licença (verificar a versão)	Pontos fortes	Uso provável no METAEXP
Qwen (Alibaba)	Densos e MoE, de pequenos a muito grandes	Apache 2.0 na maioria	Multilíngue forte, uso de ferramentas, boa relação qualidade/hardware	Candidato principal para experimentos on-premises e ajuste fino
DeepSeek	MoE muito grande; versões de raciocínio	MIT nas versões recentes	Raciocínio e código entre os melhores abertos	Raciocínio pesado; exige nó multi-GPU ou provedor
gpt-oss (OpenAI)	MoE em dois portes (≈20B e ≈120B)	Apache 2.0	Raciocínio e ferramentas; o maior roda em uma GPU de 80 GB	Bom equilíbrio para um pool de GPU enxuto

Família	Formato	Licença (verificar a versão)	Pontos fortes	Uso provável no METAEXP
Llama (Meta)	Densos e MoE, contexto longo	Licença comunitária própria, com restrições	Ecossistema grande, contexto longo	Avaliar licença com Jurídico antes de usar
Gemma (Google)	Pequenos e médios, eficientes	Termos de uso Gemma	Roda em hardware modesto, multimodal	Tarefas leves, classificação, borda
Mistral	Pequenos e médios	Apache 2.0 em vários modelos	Eficiência e boa latência	Tarefas de volume, extração simples
GLM (Zhipu) e Kimi (Moonshot)	MoE grandes, foco agêntico	MIT ou MIT modificada	Desempenho alto em tarefas agênticas	Acompanhar; exigem infraestrutura grande

Componente auxiliar	Opções abertas	Observação
Embeddings	Qwen3-Embedding (0,6B, 4B, 8B), BGE-M3, multilingual-e5	Qwen3-Embedding aparece no topo de benchmarks multilíngues e de português do Brasil
Reranker	Qwen3-Reranker, bge-reranker-v2-m3	Melhora a precisão do top-5 com custo baixo
Extração de documentos	Docling, pdfplumber, Unstructured	Docling preserva tabelas e estrutura de PDF/DOCX
PII	Microsoft Presidio + spaCy (pt)	Complementar com regras para CPF, telefone e protocolos internos
Servir modelos	vLLM, SGLang, TGI; Ollama para desenvolvimento local	vLLM expõe API compatível com OpenAI e integra com o gateway

6.3 Protocolo de benchmark interno

Benchmarks públicos não medem o que importa para o Lab. O benchmark interno usa as nossas tarefas, os nossos dados (anonimizados) e o mesmo harness de avaliação do Cientista, com Claude como referência.

Tarefa	Dados	Métrica principal
T1 · Extrair uma ficha de documento histórico	Registros ouro	F1 campo a campo; % de campos com evidência correta
T2 · Conduzir a entrevista do método	Conjunto de avaliação (personas)	% de fichas completas e válidas; turnos; nota do juiz
T3 · Julgar a qualidade de uma ficha	Fichas com nota humana	Concordância com humanos (kappa)
T4 · Responder com base no corpus (RAG)	Consultas de busca	Recall@5, MRR, fidelidade da resposta
T5 · Português corporativo	Amostra de respostas	Rubrica humana de clareza e tom
T6 · Uso de ferramentas	Conversas com ferramentas	% de chamadas válidas no esquema

Tarefa	Dados	Métrica principal
Operação	Todas	Custo por 1.000 tarefas, latência p95, memória de GPU

Critério de decisão sugerido: um modelo aberto substitui o Claude numa tarefa se ficar a no máximo 5 p.p. da referência na métrica principal, com custo total menor (incluindo GPU e operação) ou com ganho de soberania exigido pela tarefa.

6.4 Onde rodar GPUs

Opção	Quando faz sentido	Prós	Contras
API gerenciada (Claude via gateway corporativo ou nuvem)	Cientista, Analista, juiz, ingestão	Sem GPU para operar, escala imediata	Dados saem do ambiente (sob contrato); custo por token
Nuvem pública com GPU (AWS, Azure, GCP, OCI)	Pool de GPU para embeddings e experimentos	Elástico, sob demanda, instâncias spot	Verificar GPU disponível em região no Brasil; custo se ficar ligado
On-premises (data center corporativo)	Dados sensíveis, uso contínuo e previsível	Dados não saem, custo fixo	Compra e operação de hardware, prazo de aquisição
Provedores de inferência de modelos abertos	Prototipação com dados não sensíveis ou sintéticos	Rápido, sem infraestrutura	Dados saem; não usar com dados reais


Porte do modelo	Memória aproximada	GPU de referência
Embeddings e reranker ($\leq 8B$)	2 a 16 GB	1× L4 24 GB (ou CPU para volumes pequenos)
7B a 9B em 16 bits	16 a 20 GB	1× L4 24 GB
20B a 32B quantizado (4 a 8 bits)	16 a 40 GB	1× L40S 48 GB ou 1× A100 80 GB
$\approx 120B$ MoE quantizado (ex.: gpt-oss maior)	≈ 65 a 80 GB	1× H100 80 GB
$\approx 70B$ em 8 bits	≈ 70 a 80 GB	1× H100 80 GB ou 2× A100 80 GB
MoE de centenas de bilhões de parâmetros	centenas de GB	Nó com 8× H100/H200, ou usar via provedor

Recomendação

Fase 1: nenhuma GPU dedicada é obrigatória. O Cientista roda em Claude, e embeddings cabem em uma GPU L4 (ou CPU no início). Fase 2: um pool pequeno de GPU sob demanda (1× L40S ou 1× H100) atrás do gateway, servindo vLLM, com autoscaling para zero quando ocioso. Migrar para on-premises quando o volume for previsível ou quando os dados exigirem.

07

Plataforma e engenharia



7.1 Stack de referência

Peça	Escolha	Status
API	FastAPI com SSE para streaming	Existe
Front	App web por papel (chat, ficha, bancada, painel)	Protótipo existe
Banco	Postgres + pgvector	A fazer (E2)
Arquivos	Object storage (S3 ou MinIO)	A fazer
Orquestração	Máquina de estados em Python; Temporal ou fila Redis na Fase 2	Parcial
Gateway de modelos	Proxy único (ex: LiteLLM) com roteamento, cota e logs	A fazer (E1, E4)
Modelos abertos	vLLM em pool de GPU	Fase 2
Sandbox	Jobs em Kubernetes com isolamento reforçado	Fase 2 (B1)
Observabilidade	OpenTelemetry + painel de traces de LLM (ex: Langfuse)	A fazer (E4)
Avaliação	metaexp avaliar no CI a cada PR de prompt ou ferramenta	Parcial (A3)
Identidade	SSO corporativo, RBAC por papel	Onda 3 (E6)

7.2 Observabilidade e custo

- Um trace por turno: contexto montado, casos recuperados, ferramentas chamadas, tokens de entrada, saída e cache, latência e custo.
- Custo por ficha e por experimento, com alerta de orçamento mensal.
- Lead time por gate, calculado a partir dos eventos de transição (base de H1 e H4).
- Painel da esteira para o Lab (entregável G3).

7.3 Segurança

- SSO e RBAC: solicitante vê os próprios experimentos; Lab vê todos; administradores gerenciam método e golden paths.
- Mascaramento de PII em arquivos enviados antes de qualquer chamada a modelo externo.
- Proteção contra instruções embutidas em documentos (prompt injection): documentos são tratados como dados, nunca como instruções, e ferramentas com efeito externo exigem confirmação.
- Segredos em cofre corporativo, nunca no repositório.
- Trilha de auditoria imutável das decisões de gate.

08

Riscos, decisões e próximos passos

8.1 Riscos

Risco	Impacto	Mitigação
Histórico pequeno ou desorganizado	Alto	Registros ouro bem curados; sintético calibrado pela distribuição real; playbooks revisados pelo Lab
Dados pessoais nos documentos antigos	Alto	Anonimizar na ingestão; regras validadas com Segurança e Jurídico
Fichas com cara boa, mas erradas	Alto	Revisão cega pelo Lab; aprovação humana obrigatória no G0
Custo de modelo sem controle	Médio	Gateway com cota, cache de prompt, painel de custo por ficha
Mudança de versão do modelo altera o comportamento	Médio	Versão fixada no gateway; avaliação completa antes de trocar
Instruções maliciosas em documentos enviados	Médio	Documentos tratados como dados; ferramentas sensíveis com confirmação
Dependência de um único fornecedor	Médio	Gateway plugável e benchmark interno de alternativas abertas
Time dividido com outros projetos	Médio	Horas declaradas no mural; entregáveis pequenos e independentes

8.2 Perguntas em aberto

1. Onde está o histórico e quem libera o acesso?
2. Qual acesso ao Claude e qual orçamento mensal?
3. Quem é o sponsor do METAEXP como produto?
4. Quais duas áreas topam o piloto na semana 11?
5. Login corporativo já no MVP ou só no piloto?
6. Quem revisa e aprova mudanças no método?
7. Nuvem com GPU ou on-premises para os modelos abertos da Fase 2?

8.3 Próximas duas semanas

Ação	Perfil	Resultado esperado
Revisar este documento com o time e fechar as perguntas 1 a 3	PROD	Decisões registradas

Ação	Perfil	Resultado esperado
Inventariar o histórico (D1)	LAB	Planilha com cada documento e seu dono
Liberar acesso ao modelo e ambientes (E1)	ENG	Time roda o Cientista com a chave corporativa
Rodar 5 conversas reais por pessoa (C1)	Todos	Lista priorizada de falhas do Cientista atual
Congelar o método v1 (P2) e o template da ficha (P3)	LAB	Método e prompt assinados pelo Lab
Escrever as regras de uso dos dados (D2)	PROD	Regras validadas com Segurança e Jurídico

A

Apêndices

A.1 Glossário

Termo	Significado
Ficha	Documento padrão do experimento: problema, objetivo, hipótese, métricas, amostra, responsáveis
Gate	Ponto de decisão humana entre etapas (G0 a G3)
Golden path	Padrão do Lab para uma técnica: estrutura, métricas e boas práticas
Ralph Loop	Ciclo QA ↔ Desenvolvedor até $Q_k \geq 0,85$ ou 5 iterações
Q_k	Índice de qualidade: e (executa) · o (outputs existem) · d (dados válidos) · S (aderência aos critérios)
RAG	Geração aumentada por recuperação: o modelo responde com base em documentos buscados
Embedding	Representação numérica de um texto usada para busca por significado
Registro ouro	Experimento revisado campo a campo pelo Lab; gabarito da avaliação
Playbook	Cartão de conhecimento destilado do histórico por domínio e técnica
Skill	Capacidade empacotada de um agente: instruções, scripts e referências
Gateway de modelos	Proxy único para todos os modelos, com roteamento, cota e registro
Sintético	Dado gerado por modelo, rotulado como tal, para cobertura e testes

A.2 Campos da ficha

Campo	Regra
Título	No máximo 3 palavras
Problema	Descrito pelo impacto na operação
Impacto (público afetado)	Quem sente o problema e quanto custa hoje
Objetivo	O que será realizado; diferente da hipótese
Hipótese	“Acreditamos que [ação] irá gerar [resultado mensurável] para [contexto].” Máximo 2 linhas
Metodologia	Como o experimento será conduzido
Tecnologia e técnica	Classificação + golden path

Campo	Regra
Métricas	Cada uma com critério de aceite numérico
Dados e amostra	Fontes, sensibilidade, tamanho e qualidade validados
BO e Sponsor	Obrigatórios
Skills e execução	Competências necessárias; executa o Lab ou o solicitante

A.3 Rubrica do juiz (resumo)

Critério	1	3	5
Clareza do problema	Genérico ou é uma solução	Claro, sem impacto	Claro, com impacto quantificado
Hipótese	Fora do formato	No formato, pouco mensurável	No formato, mensurável e ligada às métricas
Critérios	Sem número	Números arbitrários	Números ancorados em histórico ou baseline
Condução	Várias perguntas por vez, jargão	Fluxo correto com repetições	Fluxo correto, ritmo do papel, sem repetição

A.4 Referências

- Repositório cientista-lab: `metaexp/` (agentes, contratos, método), `docs/mural/` (plano em ondas), `docs/papeis-e-responsabilidades.md`.
- Proposta original do metaexperimento (MetaExperimento_Pesquisa_Aplicada.docx).
- Prompt oficial do Cientista do beOn Labs (`metaexp/prompts/cientista.md`).
- Benchmarks públicos consultados em outubro de 2026 como ponto de partida (listas de modelos abertos e MTEB multilíngue e MTEB-BR); os números devem ser confirmados no benchmark interno.